

OPTIMASI IMAGE CLASSIFICATION PADA JENIS SAMPAH DENGAN DATA AUGMENTATION DAN CONVOLUTIONAL NEURAL NETWORK

Raga Permana¹, Handrianus Saldu², Dadang Iskandar Maulana³

Teknik Informatika, Sekolah Tinggi Ilmu Komputer
Cipta Karya Informatika, Jl. Raden Inten II No.8 , Duren
Sawit, Kota Jakarta Timur, Indonesia

e-mail: ¹raga437@gmail.com, ²andrysaldy@gmail.com, ³mahvin2012@gmail.com

Abstract

Garbage is useless goods/materials used normally or specifically in production, goods damaged during production or useless materials which mainly come from households. Moreover, inorganic waste is very difficult and takes a longer time to be decomposed by the soil. The lack of public knowledge about the classification of types of waste and how to process it causes a very serious problem in Indonesia. Therefore, this research creates a waste type recognition program using the Convolutional Neural Network (CNN) algorithm, which can be used to detect and recognize objects in an image. CNN is a technique inspired by the way mammals, humans, produce visual perception. CNN is included in the type of deep neural network because of its high network depth and widely applied to imagery. 2 Types of waste classification, namely inorganic waste and organic waste. The implementation of garbage image recognition uses 2 test models, Sequential and on top VGG16 which runs on the Google Collaboratory application, and Keras. After carrying out the Augmentation process, the number of test data in this study was 1489 images on the training data and 182 on the testing data resulting in an evaluation value with an accuracy of 90.97% and a loss value of 0.307 on the Sequential model, and an accuracy value of 97.99% with a loss value of 0.069 on the on top model. VGG16.

Keyword: Garbage, Convolutional Neural Network (CNN), Image Classification, VGG16, Augmentation.

PENDAHULUAN

Sampah adalah barang/bahan yang tidak berguna yang digunakan secara normal atau khusus dalam produksi, barang yang rusak selama produksi atau bahan yang tidak berguna (Rima Dias Ramadhani, Afandi Nur Aziz Thohari, Condro Kartiko, Apri Junaidi, Tri Ginanjar Laksana, 2021). Sampah merupakan urusan yang belum selesai dalam kehidupan manusia, Banyak permasalahan yang ditimbulkan oleh sampah sebenarnya diakibatkan oleh sikap manusia yang tidak peduli terhadap lingkungan disekelilingnya (Rahman, 2020). Sampah anorganik merupakan sampah yang sangat sulit diuraikan oleh tanah sehingga akan tertimbun dalam waktu yang sangat lama, merusak lapisan tanah dan menyebabkan pencemaran tanah, sampah anorganik contohnya, kardus, kaca, logam, plastik dan kertas. Untuk dapat mengatasi permasalahan sampah tersebut, banyak cara yang telah ditempuh seperti pengelolaan sampah yang lebih efisien, daur ulang sampah (Stephen, Raymond, & Santoso, 2019).

Untuk mengatasi permasalahan-permasalahan diatas perlu adanya kesadaran dan pengetahuan masyarakat tentang klasifikasi sampah, maka dari itu ada beberapa penelitian tentang klasifikasi sampah seperti yang dilakukan oleh Rumana Sultana beserta rekanya tentang Identifikasi Sampah dan Bahan Daur Ulang menggunakan metode *Convolutional Neural Networks* dengan akurasi antara 89,7% hingga 93,4% (Saraf et al., 2021), dan juga penelitian yang dilakukan oleh Leonardo, Yohannes dan Ery Hartati menggunakan *Support Vector Machine* dengan Fitur *Local Binary Pattern* tentang Klasifikasi Sampah Daur Ulang dengan jumlah dataset sekitar 2390 (Pattern, Validation, & Vector, 2020).

Selanjutnya penelitian yang dilakukan oleh (Arrofiqoh & Harintaka, 2018) menggunakan metode *Convolutional Neural Network* untuk klasifikasi jenis tanaman sawi dengan akurasi 100% dan 93% untuk data validasi, Dan 65% akurasi yang dilakukan oleh (Fonda, 2020)

menggunakan CNN untuk Klasifikasi Batik Riau. Sedangkan untuk Klasifikasi Penyakit Tanaman Apel Dari Citra Daun menghasilkan akurasi sebesar 97,1% yang dilakukan (Septian, Paliwang, Cahyanti, & Swedia, 2020). Selanjutnya penelitian tentang klasifikasi kerusakan bangunan sekolah menggunakan CNN dengan jumlah total citra 3000 menghasilkan akurasi 67,8%(Rizki & Marina, 2019).

Adapun penelitian yang menggunakan metode Metode GLCM dan GLRLM Menggunakan Improved KNN tentang sampah dengan jumlah citra 50 menghasilkan akurasi 90,4% pada 5 jenis sampah(Telaumbanua, Butar-butur, & Bilqis, 2021). Dan penelitian yang dilakukan oleh febian putra maulana menggunakan CNN tentang klasifikasi citra buah dengan akurasi 100% dan nilai loss 0,012, pada proses pengujian menggunakan 45 sample menghasilkan akurasi 91,42%(Maulana & Rochmawati, 2019).

Berdasarkan penjelasan tentang masalah sampah dan beberapa contoh penelitian diatas maka tujuan penelitian ini adalah untuk mengklasifikasi jenis sampah anorganik dan organik dengan menggunakan teknologi pengolahan citra gambar menggunakan metode *Convolutional Neural Network*(CNN) untuk mendapatkan nilai akurasi hasil, dengan menggunakan dua model yang ada dalam CNN yaitu model *Sequential* dan model *on top VGG-16*. Untuk memahami metode yang digunakan ini berikut penjelasan singkat tentang beberapa penjelasan dan teknologi yang digunakan.

1. Klasifikasi

Klasifikasi adalah proses menemukan pola yang dapat membagi data berdasarkan kelasnya. Untuk menemukan pola ini, Anda dapat menggunakan machine learning, yaitu kecerdasan buatan yang bekerja dengan mempelajari data historis agar sistem dapat bekerja secara optimal. Metode yang dapat melakukan klasifikasi melalui informasi prediktif objek atau data dengan presisi tinggi(Kartika Wisnudhanti, 2020). Ada banyak situasi dalam kehidupan yang mengharuskan suatu objek untuk dikategorikan ke dalam kelompok atau kelas tertentu berdasarkan sifat-sifat objek tersebut. Dalam kasus seperti itu, klasifikasi diperlukan(Akshaya & Kala MT, 2021).

2. Deep Learning

Deep Learning adalah teknik *machine learning* pada proses pembelajaran representasi berurutan dari data yang ditekankan pada jumlah lapisan jaringan syaraf tiruan yang digunakan(Kartika Wisnudhanti, 2020). *Deep learning* merupakan bagian dari *machine learning* yang menggunakan teknik *neural network* atau jaringan syaraf tiruan untuk memecahkan suatu masalah(Wicaksana, Sudarma, & Khrisne, 2019).

3. Convolutional Neural Network(CNN)

Adalah salah satu jenis *neural network* yang biasa digunakan pada data citra. CNN dapat digunakan untuk mendeteksi dan mengenali objek dalam sebuah citra. CNN merupakan pengembangan dari *Multi Layer Perceptron* (MLP) dan merupakan salah satu algoritma dari *Deep Learning*(Peryanto, Yudhana, & Umar, 2020). CNN termasuk dalam jenis jaringan saraf dalam karena kedalaman jaringannya yang tinggi dan diterapkan secara luas pada data gambar(Septian et al., 2020). Lapisan penyusun CNN terdiri dari *Convolution Layer*, *Activation ReLU Layer*, *Pooling Layer*, dan *Fully Connected Layer*(Hanin, Patmasari, & Nur, 2021). Berikut komponen utama *Convolutional Neural Network* (CNN) yaitu :

A. Convolutional Layer


Convolutional layer adalah lapisan yang terdiri dari matriks persegi panjang neuron. Bobot konvolusi mewakili saluran konvolusi. Konvolusi akan menghitung *neuron* yang terhubung ke lapisan input, masing-masing terhubung ke bobot dan wilayah kecil yang terhubung dengannya dilapisan input. Kendala yang didapat dari level *convolutional* adalah untuk mendapatkan generalisasi yang lebih baik pada *computer vision*(Bagus & Sudiarmika, 2018)(Lu et al., n.d.).



Gambar 1. Convolutional layer

B. Pooling Layer


Pooling layer digunakan untuk memperkecil ukuran, mengambil nilai terbesar dari blok persegi panjang dari *convolutional layer*, dan *down samples* untuk menghasilkan satu keluaran blok (Bagus & Sudiatmika, 2018). Ada dua jenis *pooling*, yaitu *max pooling* dan *average pooling* (Peryanto et al., 2020).



Gambar 2. Pooling Layer


C. Fully Connected Layer

Adalah yang melanjutkan fungsi aktivasi setelah mengambil *neuron* dari *layer* sebelumnya, dan juga merupakan *layer* yang berada diujung jaringan *Convolutional Neural Network* (Bagus & Sudiatmika, 2018). Keluaran dari bundel akhir atau lapisan konvolusi, yang telah diratakan kemudian ditempatkan ke dalam lapisan yang terhubung penuh. Hasil akhir *grouped* dan *convolutional layer* adalah matriks tiga dimensi, untuk melakukan *flatened* dengan mengubah semua nilai menjadi *vector* (Peryanto et al., 2020).



Gambar 3. Flatening

Flatened vector melakukan operasi matematika yang sama setelah dihubungkan ke beberapa *fully connected layer* yang sama dengan jaringan syaraf tiruan (Peryanto et al., 2020).



Gambar 4. Fully Connected Layer

D. Rectified Linear Unit (ReLU)

Adalah fungsi aktivasi linier yang banyak digunakan pada CNN. Fungsi aktivasi digunakan untuk menentukan apakah suatu neuron harus aktif atau tidak berdasarkan nilai bobot inputnya(Wicaksana et al., 2019).

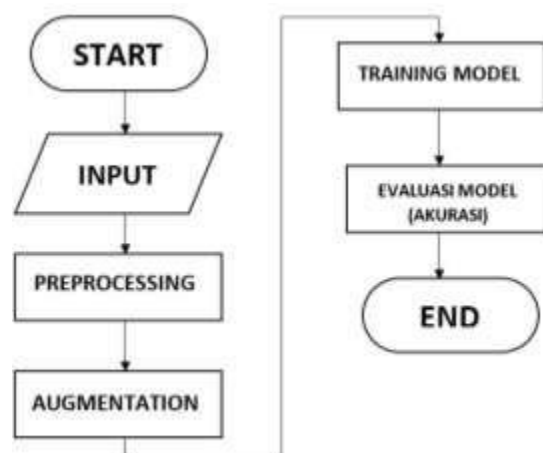
E. Softmax

Softmax merupakan bentuk lain dari *Logistic Regression* yang dapat digunakan untuk mengklasifikasi lebih dari dua kelas(Hanin et al., 2021). *Softmax* berguna untuk mengubah keluaran dari lapisan terakhir menjadi distribusi probabilitas dasarnya. Berikut adalah persamaan aktivasi *softmax* :

$$f_i(\vec{x}) = \frac{e^{x_i}}{\sum_{j=1}^k e^{x_j}} \quad (1)$$

METODE PENELITIAN

Metode penelitian ini menggunakan *framework* Keras pada *Google Collaboratory* dan *back-end Tensor Flow* dan menggunakan metode *Convolutional Neural Network* (CNN). Berikut adalah tahapan proses nya :



Gambar 5. Kerangka Uji

Dari gambar diatas tahapan pertama adalah memasukan gambar-gambar yang akan diuji dan sudah dibagi menjadi dua data set *train* dan *test*, yang memiliki ukuran yang bervariasi sehingga perlu dilakukan *preprocessing* untuk merubah ukuran gambar supaya dapat dilakukan *training* dan *testing*.


1. Preprocessing

Preprocessing adalah langkah yang dilakukan sebelum melatih atau menguji model. Pada titik ini, proses penskalaan (*Resize*), augmentasi, dan normalisasi dilakukan. Teknik ini menyesuaikan gambar sehingga dapat dilatih atau diuji. Pengubahan ukuran dilakukan dengan membuat titik-titik baru yang dipanggil kembali dengan interpolasi(Afif, Fawwaz, Ramadhani, & Sthevanie, 2020)(Knn, Pca, Warna, Aldiansyah, & Mulyana, n.d.). Dalam penelitian ini penskalaan gambar dirubah menjadi ukuran 150 X 150.

2. Augmentation

Pada gambar 5 merupakan proses atau alur program dari algoritma CNN yang dijalankan. *Augmentation* mempunyai salah satu fungsi memperbanyak gambar(Stephen et al., 2019). Sebelum melakukan augmentasi, citra yang dihasilkan akan dipotong menjadi beberapa

bagian kemudian bagian tersebut akan diubah ukurannya menjadi 150 x 150 yang selanjutnya akan dilakukan 3 jenis augmentasi data yaitu *random rotation*, *random flip* dan *crop random*(Putra et al., n.d.).



Gambar 6. Hasil Data Augmentasi

3. Dataset

Dataset pengujian yang digunakan dalam penelitian ini berjumlah 1190 data train dan pada citra data test 299 sekitar 20% dari seluruh dataset. Citra tersebut didapatkan dari internet dan situs <https://www.kaggle.com/asdasdasdas/gargarb-classification>, Berikut dataset sampah:


Tabel 1. Kategori Penelitian

Kategori	Jumlah data	Train	%	Test	%
Anorganik	838	670	80%	168	20%
Organik	651	520	80%	131	20%
Jumlah data		1489 Citra			

4. Rancangan Pengujian


Proses klasifikasi citra sampah ini menggunakan dua model pengujian yang pertama dengan model *Sequential* adalah model pengujian sederhana dengan mengambil parameter secara acak agar nilai akurasi semakin maksimal. Dan model yang kedua adalah on top VGG16, model ini sering digunakan pada penelitian-penelitian sebelumnya karena memiliki akurasi yang cukup baik, dengan mengevaluasi setiap pengujian dari model sebelumnya akan mendapatkan nilai akurasi dan *loss* yang diperoleh dari setiap model pengujian.

Seperti yang telah dijelaskan sebelumnya penelitian ini menggunakan 2 model arsitektur CNN berikut :



Gambar 7. Model Sequential

Seperti yang telah dijelaskan sebelumnya penelitian ini menggunakan 2 model arsitektur CNN berikut. Pada gambar diatas merupakan *flow* model pengujian *sequential*. Dari gambar diatas citra yang dimasukan berukuran 150x150x3 piksel dan dilakukan konversi ke *grayscale* kemudian dilakukan konvolusi dengan dua layer konvolusi dengan jumlah filter masing-masing 32 dan 64 berukuran 3x3, pada pooling layer digunakan operasi *max pooling* dengan *pooling max* berukuran 2x2 yang nantinya setiap ukuran citra akan dibagi dua saat melewati proses ini. Proses *flatten* digunakan untuk merubah format citra 2d ke 1d dengan nilai yang sudah ditentukan 150x150x3 piksel. Kemudian kita gunakan dua *dense layer*, dengan layer pertama berfungsi sebagai *activation ReLu (rectified linear unit)* berukuran 128 *neuron* dan layer kedua *Softmax* sejumlah 11 *neuron* sesuai dengan jumlah kelas data yang diambil dari dataset.



Gambar 8. Model *on top VGG-16*

Pada gambar 8 diatas adalah contoh ke 2 yang dipakai pada proses penelitian dengan memanfaatkan salah satu *feature extraction* dari *VGG16* & dilakukan training dalam *ImageNet*. Setelah menerima ekstraksi fitur dari *VGG16* tahap pertama citra yang masukan ukuran 4x4x512 piksel. Kemudian dilakukan proses *flatten* menurut citra yang sudah pada input tersebut. Kemudian dua *dense layer*, dengan layer pertama sebagai *activation ReLu (rectified linear unit)* berukuran 50 *neuron* dan layer kedua *Softmax* sejumlah 11 *neuron*.

HASIL DAN PEMBAHASAN

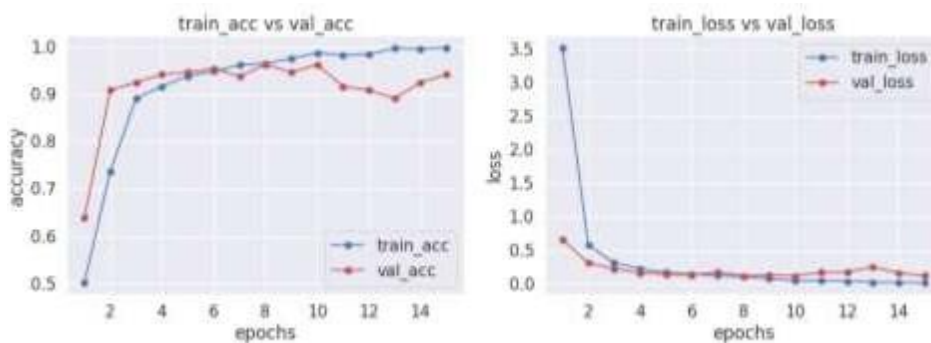
Tahap pengujian dilakukan dengan melatih model citra sampah kedalam fit model menggunakan *epoch* sebanyak 15 kali, dengan *batch size* = 128, dan *validation* = 0,2 atau 80% *training* dan 20% *validation*. *Epoch* itu sendiri adalah jumlah *neuron* yang dapat melihat semua data-data yang dikumpulkan dan *batch size* merupakan jumlah sample pelatihan didalam satu *forward / backward pass*.

1. Model Sequential

Tabel 2. Hasil *fit Model Sequential*

No	Train		Validation	
	Loss	Accuracy	Loss	Accuracy
1	3.5139	0.5010	0.6639	0.6386
2	0.5826	0.7363	0.3102	0.9075
3	0.3099	0.8907	0.2289	0.9243
4	0.2273	0.9159	0.1628	0.9411
5	0.1706	0.938	0.1472	0.9453
6	0.1479	0.9474	0.1345	0.9537
7	0.1263	0.9611	0.1779	0.9369
8	0.1086	0.9642	0.1212	0.9621
9	0.0782	0.9747	0.1297	0.9453
10	0.0469	0.9863	0.1205	0.9621
11	0.0505	0.9821	0.1711	0.9159
12	0.0447	0.9831	0.1767	0.9075
13	0.0247	0.9968	0.2541	0.8907
14	0.0256	0.9947	0.1624	0.9243
15	0.0174	0.9978	0.1249	0.9411

Pada table 2 merupakan hasil pelatihan data *training* dan data *validation* dengan menggunakan *epoch* 15 kali, Dan mendapatkan nilai *accuracy* dan nilai *loss* dari data *train* dan data *validation*. Nilai akurasi(*accuracy*) merupakan nilai yang dapat dipakai sebagai acuan dalam mengetahui tingkat kesuksesan/kelayakan model yang sebelum nya di buat dan nilai *loss* merupakan ukuran dari kegagalan/kesalahan yang dibuat *networks* bertujuan untuk meminimalisirnya. Pada data *train* diperoleh nilai *accuracy* sebesar 0.9978 pada *epoch* ke-15 dan nilai *loss* terendah 0.0174 pada *epoch* ke-15, dan pada data *validation* diperoleh nilai akurasi tertinggi sebesar 0.9621 pada *epoch* ke-10 dan 8 sedangkan nilai *loss* terendah 0.1205 pada *epoch* ke-10. Dari hasil pelatihan data *train* dan data *validation* tersebut dapat kita visualisasikan kedalam bentuk plot/grafik sebagai berikut :



Gambar 9. Accuracy Loss Model Sequential

Dari gambar 9 di atas diketahui bahwa relasi antara nilai *accuracy* dan nilai *loss* pada data *train* dan data *validation* dengan jumlah *epoch*/iterasi. Hubungan yang terjadi pada nilai *accuracy* menunjukkan korelasi yang positif yang memiliki hubungan satu arah dengan ketentuan semakin banyak jumlah *epoch* yang dilakukan maka nilai *accuracy* data *train* dan data *validation* semakin bagus. Sebaliknya sesuai dengan nilai *accuracy*, hubungan antara jumlah

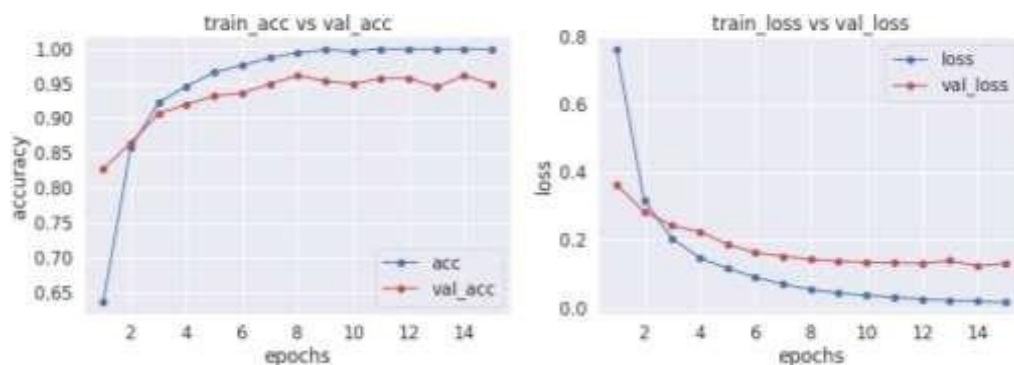
epoch dengan nilai *loss* merupakan korelasi yang negatif dimana banyak jumlah *epoch* yang digunakan akan mempengaruhi nilai *loss* yang dihasilkan pada pelatihan data semakin kecil. Dapat disimpulkan bahwa untuk memperkecil nilai *loss* yang ingin diharapkan maka dapat dilakukan dengan cara meningkatkan jumlah *epoch* pada proses *training*. Hasil penelitian yang menggunakan *model sequential* diatas menghasilkan nilai dari data *train* sebesar 90.97% dan nilai *loss* sebesar 0.307.

2. Model on top VGG16

Tabel 3. Hasil *fit Model on top VGG16*

No	Train		Validation	
	Loss	Accuracy	Loss	Accuracy
1	0.7639	0.6366	0.3634	0.8277
2	0.3167	0.8592	0.2844	0.8655
3	0.2056	0.9233	0.2434	0.9076
4	0.1484	0.9464	0.2252	0.9202
5	0.1167	0.9664	0.188	0.9328
6	0.0917	0.9769	0.1638	0.937
7	0.0702	0.9874	0.1526	0.9496
8	0.0552	0.9947	0.1441	0.9622
9	0.0446	0.9989	0.1380	0.9538
10	0.0376	0.9968	0.1355	0.9496
11	0.0323	1	0.1332	0.958
12	0.0267	1	0.1317	0.958
13	0.0228	1	0.1397	0.9454
14	0.0201	1	0.1241	0.9622
15	0.0175	1	0.1319	0.9496

Dari table 3 diatas dapat dilihat hasil pengujian dari model yang kedua yaitu *on top VGG16* dengan jumlah *epoch* sebanyak 15 kali. Dari data tersebut menghasilkan nilai akurasi tertinggi 1 pada epoch ke-11 sampai dengan ke-15 sedangkan nilai *loss* terendah 0.0175 pada *epoch* ke-15. Kemudian pengujian pada data validasi menghasilkan nilai akurasi tertinggi sebesar 0.9622 pada *epoch* ke-8 dan 14, sedangkan nilai *loss* terendah 0.1241 pada *epoch* ke-14. Berikut hasil data pengujian dari tabel diatas dapat kita visualisasikan kedalam plot/diagram.



Gambar 10. Accruracy dan Loss Model ontop VGG16

Pada gambar 10 diatas merupakan hubungan antara nilai *accuracy* dan nilai *loss* pada data *train* dan data *validation* dari banyak nya iterasi pada model penelitian yang kedua. Dapat dilihat bahwa model kedua ini memiliki korelasi nilai *accuracy* yang searah baik pada data *train* maupun data *validation* dan berbanding dengan nilai *loss* juga. Dari pengujian menggunakan *model on top VGG16* diperoleh nilai evaluasi kinerja yang dihasilkan pada data *test* dengan nilai akurasi sebesar 97.99% dan nilai *loss* sebesar 0.069.

3. Evaluasi

Evaluasi dari hasil kedua model yang telah diuji yaitu model *sequential* dan model *on top VGG16* yang menggunakan data train sebanyak 1190 citra diperoleh nilai evaluasi yang dihasilkan dari data *test* sebanyak 299 citra dengan menggunakan *epoch* sebanyak 15 kali, *batch size* = 128, dan *validation split* = 0,2 didapat nilai *accuracy* sebagai berikut :

Tabel 4. Evaluasi nilai *Accuracy* dan nilai *Loss*

<i>Model sequential</i>		<i>Model on top VGG16</i>	
<i>Accuracy</i>	<i>Loss</i>	<i>Accuracy</i>	<i>Loss</i>
90.97%	0.307	97.99%	0.069

KESIMPULAN

Berdasarkan hasil klasifikasi 2 jenis sampah menggunakan metode *Convolutional Neural Network* (CNN) menghasilkan kesimpulan bahwa untuk dapat melewati proses preprocessing dengan baik ukuran citra yang ada harus dirubah dimensinya menjadi 150x150x3 piksel dan konversi warna citranya menjadi *grayscale* pada model *Sequential*, kemudian menggunakan *feature extraction VGG16* yang *ditraining* didalam *ImageNet* dengan ukuran dimensi 4x4x512 piksel pada *on top VGG16*. Akurasi yang di hasilkan akan semakin bagus apabila data *train* yang digunakan semakin banyak. Hal tersebut di buktikan dengan pengujian pada jumlah data *training* sebanyak 80% dan data *validation* 20%. Pada setiap model pengujian. Maka dari itu digunakan *Augmentation* untuk memperbanyak data nya, dengan menggunakan *crop* dan *flip* agar akurasi dalam penelitian ini mendapat nilai akurasi yang bagus. Dengan melakukan evaluasi pengujian model *Sequential* dan model *on top VGG16* dengan *epoch* sebanyak 15 kali, *batch size* = 128, dan *validation split* = 0,2 , menghasilkan nilai *accuracy* dan nilai *loss* pada data *test* sebesar 90.97% dan nilai *loss* 0.307 pada model *Sequential*, serta pada model *on top VGG16* menghasilkan nilai akurasi sebesar 97.99% dengan nilai *loss* 0.069.

SARAN

Dalam pengembangan aplikasi selanjutnya agar memperbanyak citra dataset, dan menggunakan nilai *epoch* yang lebih banyak agar nilai akurasi dari kedua model semakin tinggi dan nilai *loss* nya semakin rendah, ataupun bisa menggunakan model selain model *sequential* dan model *VGG16*. Dan untuk kedepannya diharapkan agar teknologi ini bisa diaplikasikan pada masyarakat.

DAFTAR PUSTAKA

- Afif, M., Fawwaz, A., Ramadhani, K. N., & Sthevanie, F. (2020). Klasifikasi Ras pada Kucing menggunakan Algoritma Convolutional Neural Network(CNN). *Jurnal Tugas Akhir Fakultas Informatika*, 8(1), 715–730.
- Akshaya, B., & Kala MT, P. (2021). *Gambar Berbasis Jaringan Saraf Konvolusi Klasifikasi Dan Deteksi Kelas Baru*.

- Arrofiqoh, E. N., & Harintaka. (2018). IMPLEMENTASI METODE CONVOLUTIONAL NEURAL NETWORK UNTUK KLASIFIKASI TANAMAN PADA CITRA RESOLUSI TINGGI (The Implementation of Convolutional Neural Network Method for Agricultural Plant Classification in High Resolution Imagery). *Geomatika*, 24(2), 61–68.
- Bagus, I., & Sudiatmika, K. (2018). *Gambar Wayang Kulit Tradisional Indonesia Klasifikasi : Pendekatan Pembelajaran Mendalam*. 130–135.
- Fonda, H. (2020). Klasifikasi Batik Riau Dengan Menggunakan Convolutional Neural Networks (Cnn). *Jurnal Ilmu Komputer*, 9(1), 7–10. <https://doi.org/10.33060/jik/2020/vol9.iss1.144>
- Hanin, M. A., Patmasari, R., & Nur, R. Y. (2021). Sistem Klasifikasi Penyakit Kulit Menggunakan Convolutional Neural Network (Cnn) Skin Disease Classification System Using Convolutional Neural Network (Cnn). *E-Proceeding of Engineering*, 8(1), 273–281.
- Kartika Wisnudhanti, F. C. (2020). *Metode Convolutional Neural Network Dalam Klasifikasi Citra Tiga Tokoh Wayang Pandawa*. 7(2018), 1–5.
- Knn, M., Pca, D., Warna, B., Aldiansyah, R., & Mulyana, D. I. (n.d.). *Implementasi Klasifikasi Tingkat Kematangan Buah Belimbing Dengan*. 1–8.
- Lu, S., Lu, Z., Aok, S., Graham, L., Pendidikan, S. I., Nanjing, U. N., ... Reap, P. S. (n.d.). *Klasifikasi Buah Berdasarkan Jaringan Saraf Konvolusi Enam Lapisan konvensional Sisa dari naskah ini disusun sebagai berikut : klasifikasi . Dengan operasi konvolusi dan Sebagai algoritma deep learning , CNN telah dalam hal akurasi klasifikasi . Jaringan .*
- Maulana, F. F., & Rochmawati, N. (2019). Klasifikasi Citra Buah Menggunakan Convolutional Neural Network. *Journal of Informatics and Computer Science*, 01, 104–108.
- Pattern, L. B., Validation, K. C., & Vector, S. (2020). *Klasifikasi Sampah Daur Ulang Menggunakan Support Vector Machine DENGAN Fitur Local Binary Pattern*. 1(1), 78–90.
- Peryanto, A., Yudhana, A., & Umar, R. (2020). Klasifikasi Citra Menggunakan Convolutional Neural Network dan K Fold Cross Validation. *Journal of Applied Informatics and Computing*, 4(1), 45–51. <https://doi.org/10.30871/jaic.v4i1.2017>
- Putra, R. F., Mulyana, D. I., Huda, F. N., Inaldy, N., Timur, C., Barat, K. J., ... Augmentasi, D. (n.d.). *OPTIMASI IMAGE CLASSIFICATION PADA BURUNG SATWA LANGKA DI PAPUA DENGAN DATA AUGMENTASI DAN CONVOLUTIONAL*. 1–10.
- Rahman, M. F. (2020). *Deteksi Sampah pada Real-time Video Menggunakan Metode Faster R-CNN*. 3(2), 117–125.
- Rima Dias Ramadhani, Afandi Nur Aziz Thohari, Condro Kartiko, Apri Junaidi, Tri Ginanjar Laksana, N. A. S. N. (2021). *Optimasi Akurasi Metode Convolutional Neural Network untuk*. 1(10), 11–12.
- Rizki, A. M., & Marina, N. (2019). Klasifikasi Kerusakan Bangunan Sekolah Menggunakan Metode Convolutional Neural Network Dengan Pre-Trained Model Vgg-16. *Jurnal Ilmiah Teknologi Dan Rekayasa*, 24(3), 197–206. <https://doi.org/10.35760/tr.2019.v24i3.2396>
- Saraf, J., Cnn, K., Teknologi, S. T., Adams, R. D., Tanaka, M. L., & Yanik, P. M. (2021). *Jaringan Saraf Konvolusi (CNN)*.
- Septian, M. R. D., Paliwang, A. A. A., Cahyanti, M., & Swedia, E. R. (2020). Penyakit Tanaman Apel Dari Citra Daun Dengan Convolutional Neural Network. *Sebatik*, 24(2), 207–212. <https://doi.org/10.46984/sebatik.v24i2.1060>
- Stephen, Raymond, & Santoso, H. (2019). Aplikasi Convolution Neural Network untuk Mendeteksi Jenis-jenis Sampah. *Explore – Jurnal Sistem Informasi Dan Telematika*, 10(2), 122–132.
- Telaumbanua, K., Butar-butur, F., & Bilqis, P. S. (2021). *Identifikasi Sampah Berdasarkan Tekstur dengan Metode GLCM dan GLRLM Menggunakan Improved KNN*. 1(2), 45–52.
- Wicaksana, P. A., Sudarma, I. M., & Khrisne, D. C. (2019). Pengenalan Pola Motif Kain Tenun Gringsing Menggunakan Metode Convolutional Neural Network Dengan Model Arsitektur. *Jurnal SPEKTRUM*, 6(3), 159–168.